

基于改进 U-Net 卷积神经网络的焊缝特征提取

熊垒垒, 朱学军*, 赖惠鸽, 余拆操, 毛坤, 杨明, 彭达

宁夏大学机械工程学院, 宁夏 银川 750021

摘要 针对在实际焊接环境中弧光等噪声干扰导致焊缝特征提取精度下降的问题,提出了一种改进的 U-Net 模型来提高激光条纹的提取效率。首先,以 VGG16 为编码器基础,结合迁移学习策略来增强模型的鲁棒性。其次,在解码器部分,通过结合标准卷积和深度可分离卷积的多尺度融合模块,并引入瓶颈层结构,设计了一个轻量化的跨层连接网络模块,旨在降低模型的计算负担和参数量。此外,还提出了一种轻量化的坐标注意力机制,以增强瓶颈层的特征表示,从而提升分割质量。最后,通过跳跃连接实现了编码器和解码器之间不同分辨率特征的有效融合。实验结果表明,该方法在存在弧光干扰的焊接环境中表现出色,能够有效提高分割精度,显示出在实际应用中的价值。

关键词 焊缝提取; 注意力机制; U-Net; 轻量化

中图分类号 TP391.4; TN41

文献标志码 A

DOI: 10.3788/LOP250654

Weld Seam Feature Extraction Based on Improved U-Net
Convolutional Neural Network

Xiong Leilei, Zhu Xuejun*, Lai Huige, Yu Checao, Mao Kun, Yang Ming, Peng Da

School of Mechanical Engineering, Ningxia University, Yinchuan 750021, Ningxia, China

Abstract An improved U-Net model is proposed to improve the efficiency of laser stripe extraction to address the issue of decreased accuracy in weld seam feature extraction caused by noise interference such as arc light in actual welding environments. First, VGG16 is used as the encoder foundation and transfer learning strategies are incorporated to enhance the robustness of the model. Second, in the decoder section, a lightweight cross-layer connectivity network module is designed by combining standard convolution and depthwise separable convolution in a multiscale fusion module as well as by introducing a bottleneck layer structure to reduce the computational burden and parameter count of the model. Additionally, this study proposes a lightweight coordinate attention mechanism to enhance the feature representation of bottleneck layers, thereby improving segmentation quality. Finally, different resolution features between the encoder and decoder are fused effectively via skip connections. Experimental results show that this method performs well in welding environments with arc interference, thus effectively improving segmentation accuracy and demonstrating its value in practical applications.

Key words weld seam extraction; attention mechanism; U-Net; lightweight

1 引言

焊接技术是现代制造业的关键工艺,但传统人工焊接难以满足现代制造对质量和效率的要求。因此,搭载智能传感器的焊接机器人应运而生,逐渐成为智能焊接的主导力量^[1-2]。其中,线结构光传感器因其非接触测量、结构简洁、检测精度高等优势被广泛采用。该传感器通过投射线状光束获取焊缝信息,但在实际焊接中,弧光、飞溅等干扰因素会遮挡结构光图像,影响焊缝信

息的准确提取。因此,如何高效提取激光条纹是线结构光传感器在焊接领域应用中的关键技术难题。

迄今为止,众多学者已深入探索焊接自动化技术领域中的焊缝跟踪问题,并开发出了多种基于图像处理技术的策略,旨在有效提取激光条纹的中心线。鉴于激光条纹的灰度值分布通常呈现出理想高斯分布的特性,研究者们采用了几何中心法^[3]、灰度重心法^[4-5]、阈值法^[6]以及 Steger 算法^[7]等方法来提取中心线。尽管这些基于图像处理的手段在一定程度上解决了线结

收稿日期: 2025-02-18; 修回日期: 2025-03-10; 录用日期: 2025-03-12; 网络首发日期: 2025-03-24

基金项目: 国家自然科学基金(51765056)

通信作者: *zhxj@nxu.edu.cn

构光特征提取的问题,但是,实际应用中,激光条纹的光强分布往往受到焊接过程中弧光、飞溅物、烟雾等噪声因素的干扰,其灰度值偏离理想的高斯分布。因此,这些方法的适用性和鲁棒性在实际焊接环境中受到了限制。为弥补传统方法在强弧光和焊渣飞溅干扰下的不足,张世宽等^[8]提出了基于 U-Net 的轻量化激光条纹中心提取算法,该方法在一定程度上具有抗干扰性。然而,在极端噪声条件下,尤其是当激光条纹因弧光和飞溅物的强烈干扰而不完整时,该方法的中心线提取精度会显著降低。Yu 等^[9]基于 PSP-Net 提出了一种焊缝结构光中心线提取方法。该方法能够在轻度干扰环境下快速完成焊缝图像的分割,具有较强的实时性能,但在复杂环境下的抗干扰性能欠佳。Rashid 等^[10]通过训练 Faster R-CNN 模型,实现了焊缝类型的自动识别以及激光条纹感兴趣区域(ROI)的定位。在焊缝跟踪过程中,通过两步提取算法精确获取焊缝边缘,并结合 Steger 算法提取激光条纹。通过精确定位 ROI,该方法有效降低了焊接过程中弧光和飞溅等因素对条纹边界提取的干扰。在特定噪声条件下,该方法对 V 型焊缝表现出良好的识别效果。然而,其局限性在于对其他复杂焊缝类型的适用性较低,从而限制了其在更广泛场景中的应用。

鉴于实际焊接环境中复杂噪声对焊缝识别准确率的负面影响,本文设计了一种增强 U-Net 焊缝识别鲁

棒性的改进算法。在特征提取阶段使用带迁移学习的 VGG16 作为解码器,在特征融合阶段使用轻量化的 GSConv 代替普通卷积,并将 GSConv 嵌入跨层网络模块 VoVGSCSP 的瓶颈结构,以强化模型对特征层空间与通道内关键信息的捕捉能力,使得模型在具有较高特征提取能力的同时实现轻量化。此外,提出一种全局分组坐标注意力(GGCA)机制,用以实现特征的精细化加权整合。所提算法在焊缝激光条纹分割中表现优异,为嵌入式系统中的焊接自动化提供参考。

2 数据集采集与构建

研究中,采用全视 FV-160 系列激光焊缝跟踪传感器,获取实际焊接过程中的焊缝图像。实验中,采集带有弧光、飞溅等干扰的原始焊接图像。待焊接工件被固定于传感器下方,传感器发射线激光以照射焊缝区域,采样频率设定为 50 Hz,采集到的图像分辨率为 512 pixel $\times$ 512 pixel,数据采集平台如图 1 所示。鉴于网络训练的硬件资源限制,采集的图像在输入网络前被调整为 256 pixel $\times$ 256 pixel,以降低计算复杂度;网络输出后,将图像重新调整回原始大小以恢复细节。此外,为增强数据集的多样性和代表性,对采集到的图像进行了数据增强处理,最终构建了一个包含 1138 张图像的数据集。该数据集按照 7:2:1 的比例划分为训练集、验证集和测试集,部分样本图像如图 2 所示。




图 1 数据采集平台。(a) FV-160 焊缝跟踪传感器;(b)数据采集示意图

Fig. 1 Data collection platform. (a) FV-160 weld seam tracking sensor; (b) data collection diagram




图 2 部分数据集

Fig. 2 Partial dataset

3 改进 U-Net 网络结构

提出的改进型 U-Net 网络结构如图 3 所示,其中 1

是指输入图像通道数为 1,之后的数字代表每一层网络的通道数。在编码器的特征提取层引入了 VGG16 模块,以充分利用其卓越的特征提取能力。为进一步优化网络的轻量化设计,将 VoVGSCSP 模块嵌入解码器架构,通过一系列变换生成具有相似特性的中间特征图,并进行高维卷积操作,旨在减少模型参数并降低计算复杂度。此外,在 VoVGSCSP 模块中融入了 GGCA 机制,通过自适应调整空间特征图的权重,使网络能够更精准地聚焦图像中的关键信息,从而显著提升特征的区分度。最终,通过编码器与解码器之间的跳跃连接,将编码器各阶段的特征层输出与解码器进行深度融合,有效保留了浅层特征层中的细节信息,并整合了全局上下文信息,显著提升了信息的完整性和利用率,从而实现了高质量的条纹分割。




图 3 改进 U-Net 模型结构图

Fig. 3 Improved U-Net model structure

3.1 VGG16 预训练编码器

U-Net^[11]神经网络通过编码-解码架构和跳跃连接实现端到端语义分割,但其原生编码器特征提取能力有限,难以应对焊接场景中的复杂噪声干扰。

为提升网络的特征提取能力,采用预训练的 VGG16 网络^[12]作为特征提取器,替代原生 U-Net 的编码器部分。这一改进的核心在于借助 VGG16 在大规模数据集(如 ImageNet)上预训练所获得的强大特征提取能力,实现对输入图像更丰富、更具语义性的特征表示。通常情况下,U-Net 从随机初始化的权重开始训练,这要求数据集规模足够大以避免过拟合。然而,构建大规模数据集往往需要耗费大量的人力和物力,且在实际应用中难以实现。因此,引入迁移学习策略^[13-14],将在 ImageNet 数据集上预训练得到的 VGG16 网络权重作为模型的初始权重,并仅对未预训练的网络层进行微调。通过这种方式,模型能够快速收敛并

有效提升性能,同时减少对大规模数据集的依赖。如图 4 所示,学习过程主要集中在对未预训练层的优化上。以 VGG16 网络为编码器的模型具体结构如图 5 所示。




图 4 迁移学习训练过程

Fig. 4 Transfer learning training process




图 5 含有 VGG16 的 U-Net 模型结构图

Fig. 5 U-Net model structure diagram with VGG16

3.2 GGCA 机制

注意力机制^[15]是机器学习中的一种数据处理方法,广泛应用于自然语言处理(NLP)、图像处理和语

音识别等领域。它使算法能够专注于特定区域,从而提取更详细的信息,提升表达能力。

U-Net 神经网络基于下采样和跳跃连接实现特征

提取与传递,但该过程易引入冗余信息,造成信息传递不完整和不确定性。同时,模型在特征融合时仅采用简单拼接方式,难以充分捕捉丰富特征,尤其是在处理激光条纹与背景像素不平衡的数据集时,这种局限性更为显著。为此,当前研究普遍采用引入注意力机制的策略,以增强模型对特征信息的学习能力,有效抑制无关像素干扰。然而,现有注意力机制为提升模型精度,常引入大量额外变量,导致模型复杂度增加和计算效率降低。

对此,提出了 GGCA 机制,其结构如图 6 所示。该

机制由分组操作和空间权重计算两个部分组成。在分组阶段,输入特征图按照通道数 C 被均匀划分为 G 组,以降低模型的计算复杂度。在空间维度,分别在高度 H 和宽度 W 方向对每组特征进行全局平均池化和全局最大池化操作。对于每个分组特征图,进一步通过共享的跨维度卷积层进行特征处理,以实现通道的降维与恢复。最终,将卷积层的输出合并,并通过 Sigmoid 函数激活,生成高度和宽度方向的注意力权重。这些权重用于对输入特征图进行加权,从而得到特征增强后的输出特征图。




图 6 GGCA 机制结构图

Fig. 6 Structure diagram of GGCA mechanism

为了减少计算量并保留通道间的局部相关性,对输入特征图进行通道分组,以便对每个分组独立处理。原始特征图 F_{in} 的尺寸为 $N \times C \times H \times W$,按 G 组进行分组,分组后的特征图表示为

$$F_g = \text{Reshape}\left(F_{in}, \left(N, G, \frac{C}{G}, H, W\right)\right) \quad (1)$$

对每个分组的特征图 F_g ,分别在高度方向和宽度方向进行全局平均池化和最大池化,提取全局信息,以便后续生成注意力权重。高度方向的全局池化可表示为

$$F_{g,h,avg} = \text{AdaptiveAvgPool2d}(F_g, (h, 1)) \quad (2)$$

$$F_{g,h,max} = \text{AdaptiveMaxPool2d}(F_g, (h, 1)) \quad (3)$$

宽度方向的全局池化可表示为

$$F_{g,w,avg} = \text{AdaptiveAvgPool2d}(F_g, (1, w)) \quad (4)$$

$$F_{g,w,max} = \text{AdaptiveMaxPool2d}(F_g, (1, w)) \quad (5)$$

式中: h, w 为输出特征图的高度和宽度。

通过共享卷积层对池化后的特征进行处理,提取通道间的相关性,同时减少计算量和参数量。共享卷积层由两个卷积层组成,分别用于通道降维和恢复。共享卷积层可表示为

$$S(X) = \text{Conv2d}\left(\text{ReLU}\left(\text{BatchNorm2d}\left(\text{Conv2d}(X, (1, 1))\right)\right), (1, 1)\right) \quad (6)$$

通过 Sigmoid 激活函数生成高度方向和宽度方向的注意力权重,可表示为

$$A_{g,h} = \text{Sigmoid}\left(S(F_{g,h,avg}) + S(F_{g,h,max})\right) \quad (7)$$

$$A_{g,w} = \text{Sigmoid}\left(S(F_{g,w,avg}) + S(F_{g,w,max})\right) \quad (8)$$

将注意力权重应用到每个分组的特征图上,增强特征图的重要部分,从而提高模型对关键特征的关注度,可表示为

$$F_{g,att} = F_g \odot A_{g,h} \odot A_{g,w} \quad (9)$$

$$F_{out} = \text{Concat}(F_{1,att}, \dots, F_{G,att}) \quad (10)$$

式中: $\odot$ 为点乘操作。

3.3 轻量上采样解码器

在实际工业生产环境中,受限于设备端的内存容量和计算能力,大规模模型难以直接部署和应用。因此,构建高性能的图像分割模型不能单纯依赖增加模型参数量,而应注重模型的轻量化设计,以适应工业场景的实际需求。轻量化技术可降低模型参数量和计算复杂度,同时保持或提升模型性能,已成为工业领域模型优化的重要方向。

GSConv 模块^[16]是一种结合密集卷积与稀疏卷积的轻量化卷积层结构。与传统标准卷积不同,GSConv 通过在特征图中引入全局稀疏性,并在通道

间维持广泛的连接,实现了全局信息的有效聚合,同时仅对稀疏位置进行卷积计算。这种设计在降低计算复杂度的同时,保留了丰富的特征信息。如图 7 所示,输入特征图首先经过标准卷积进行下采样,然后进行深

度可分离卷积操作。在通道维度上,将标准卷积和深度可分离卷积后的特征图进行拼接,并通过 Shuffle 操作将标准卷积生成的信息融入深度可分离卷积,从而增强特征间的交互作用。




图 7 GSConv 结构图

Fig. 7 GSConv structure diagram

GSConv 模块因其显著的非线性特性在轻量化检测器中表现出色,这一优势主要源于其融合了深度可分离卷积层^[17]和 Shuffle 操作。然而,过度依赖 GSConv 会导致网络深度增加,进而降低数据传输效率并延长推理时间。为解决这一问题,文献[16]提出了 GS 瓶颈模块,该模块在瓶颈部分整合了 GSConv 与卷积块,如图 8(a)所示,其中 C_1 代表输入特征图的通道数, C_2 代表输出特征图的通道数。在此阶段,特征图的通道数达到最大,而空间维度(宽度和高度)被压缩至最小,无需额外的转换步骤。此时通过 GSConv 优化这些特征图,可有效减少信息冗余,省略了不必要的压缩步骤。

尽管 GSConv 在降低计算负担方面表现出色,但

为了进一步提升推理速度并保持模型性能,仍须探索更为高效的架构。因此,文献[16]进一步提出了 VoVGSCSP 模块,如图 8(b)所示。该模块通过集成 GS 瓶颈模块,在减少模型参数数量和计算需求的同时,保持较高的识别精度。这种结构设计简洁高效,为轻量化模型的优化提供了新的思路。

在深度学习模型中,特征表达能力对模型的最终性能起着决定性作用。为了进一步提升 VoVGSCSP 模块的特征提取能力,在其卷积块之后引入了 GGCA 机制,如图 8(c)所示。GGCA 机制通过提升特征图的判别力和区分度,提升模型对关键视觉信息的敏感性,进而优化模型在分割和识别任务中的性能。




图 8 上采样网络结构。(a) GS 瓶颈;(b) VoVGSCSP;(c)改进的 VoVGSCSP

Fig. 8 Upsampling network structure. (a) GS bottleneck; (b) VoVGSCSP; (c) improved VoVGSCSP

3.4 混合损失函数

在焊接场景中,工业相机采集的焊缝激光数据集包含激光条纹、无关背景以及烟雾、弧光和飞溅等干扰

因素。激光条纹作为关键特征,在图像中所占比例极小,正样本数量显著少于负样本数量,导致类别分布严重失衡。这一现象使得网络训练过程不稳定,模型易

陷入损失函数的局部极小值,进而生成偏向背景类别的预测结果,显著降低网络对目标区域的分割精度。

为缓解上述问题,采用 Dice 损失函数^[18]与 Focal 损失函数^[19]进行联合优化。Dice 损失函数通过量化预测结果与真实标签之间的重叠程度,有效抑制背景信息对模型训练的干扰,从而提升模型对目标区域的分割精度。Focal 损失函数则通过调整损失权重,降低易分类样本的权重贡献,同时增加难分类样本的权重,促使模型更多地聚焦于难以正确分类的样本。这种权重调整机制有效缓解了样本不平衡带来的训练难题,显著增强了模型对少数类别的识别能力。采用 Focal 损失和 Dice 损失对网络进行训练,以解决激光条纹与背景像素比例失调导致的识别结果偏向背景的问题,表达式如下:

$$L_{\text{Dice}} = 1 - \frac{2|X \cap Y| + 1}{|X| + |Y| + 1} \quad (11)$$

$$L_{\text{Focal}} = -\alpha(1-y)^\gamma \log y \quad (12)$$

$$L = \omega L_{\text{Focal}} + (1-\omega) L_{\text{Dice}} \quad (13)$$

式中: L_{Focal} 为 Focal 损失函数; L_{Dice} 为 Dice 损失函数; X 为焊缝激光条纹预测像素数量; Y 为焊缝激光条纹真实像素数量; y 为预测为正样本的概率; α 为平衡因子; γ 为焦点因子; ω 为权重系数。

4 实验结果与分析

4.1 实验环境与评价指标

实验训练模型平台硬件配置为 CPU AMD Ryzen 7 7840H、GPU NVIDIA GeForce RTX 4060、32 GB DDR5 内存,实验环境为 64 bit Windows 11 系统。软件环境为 PyCharm、Python 3.9、PyTorch 2.3.1、CUDA 12.1,使用 PyTorch 深度学习框架搭建、训练以及测试网络模型。以 Adam 为模型的优化器,将动量参数设置为 0.9,学习率采用余弦退火衰减策略。网络迭代次数设置为 200 轮,批尺寸设置为 4。

模型的评价指标包括:准确率(ACC)、平均交并比(mIoU)、平均像素精度(mPA)和每秒帧数(FPS)。ACC 是衡量模型像素分类正确性的指标,其值越高代表模型质量越好;mIoU 通过计算预测结果与真实标签之间每个类别的交集与并集之比,综合反映了模型对不同类别像素的分割精度;mPA 计算每个类别像素的平均正确分类率,重点关注模型对各类别像素的分类准确性;FPS 反映了模型的实时处理能力,对于实际焊接生产中的在线应用具有重要意义。相关指标的具体计算方法为

$$I_{\text{ACC}} = \frac{N_{\text{TP}} + N_{\text{TN}}}{N_{\text{TP}} + N_{\text{TN}} + N_{\text{FP}} + N_{\text{FN}}} \quad (14)$$

$$R_{\text{mIoU}} = \frac{1}{2} \left(\frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FN}} + N_{\text{FP}}} + \frac{N_{\text{TN}}}{N_{\text{TN}} + N_{\text{FN}} + N_{\text{FP}}} \right) \quad (15)$$

$$I_{\text{mPA}} = \frac{1}{2} \left(\frac{N_{\text{TP}}}{N_{\text{TP}} + N_{\text{FP}}} + \frac{N_{\text{TN}}}{N_{\text{TN}} + N_{\text{FN}}} \right) \quad (16)$$

$$I_{\text{FPS}} = \frac{F}{T} \quad (17)$$

式中: N_{TP} 为分割正确的焊缝特征像素数; N_{TN} 为分割正确的焊缝背景像素数; N_{FP} 为分割错误的焊缝特征像素数; N_{FN} 为分割错误的焊缝背景像素数; F 为检测图片数量; T 为检测图片所用的总时间。

4.2 VGG16 预训练编码器性能实验

在迁移学习与非迁移学习场景下对在相同训练条件下改进的 U-Net 模型进行对比分析,如图 9 所示。结果显示,运用迁移学习的模型的收敛速率明显高于未采用迁移学习的模型,并且能够达到更低的损失值。这表明迁移学习在模型训练中具有显著优势,尤其是在训练样本不足时。预训练模型从 ImageNet 数据集中获取的特征能够有效迁移至焊缝激光条纹分割任务,显著增强了模型性能。




图 9 迁移学习对模型训练损失的影响

Fig. 9 Impact of transfer learning on model training loss

4.3 超参数调整

在探究网络模型学习效果的过程中,损失函数中权重参数的配置以及 GGCA 机制中的分组数量是决定模型性能的关键因素。通过在测试集上系统地调整这些超参数的取值,深入剖析其对模型性能的影响机制。基于一系列细致的观察和严谨的统计分析,构建一个优化的超参数配置方案,以提升模型的整体效能。

在深度学习领域,损失函数的超参数调整是优化模型性能的关键环节之一。加权混合损失函数的设计初衷在于整合多种单一损失函数的优势,从而显著提升模型的综合表现能力。其重要性体现在能够在训练过程中兼顾多个关键维度,例如目标分布的均衡性、结构相似度以及区域预测的准确性等。这种多维度的学习策略有助于模型对目标特征进行更为全面且深入的学习。通过对表 1 中各项评价指标的对比分析,可以直观地量化加权混合损失函数对模型性能提升的贡献程度。

在分割模型中,采用 Dice 损失(权重为 0.6)与 Focal 损失(权重为 0.4)的组合策略。这种权重配置引

表 1 不同损失函数权重系数下的模型性能对比

Table 1 Comparison of model performance under different weight coefficients of loss functions

ω	mPA / %	mIoU / %
0	95.67	89.76
0.2	95.78	90.11
0.4	95.83	90.23
0.6	95.76	90.04
0.8	95.69	89.92
1.0	95.53	89.66

导模型在实现精确分割同时,侧重于难分类像素,从而有效改善了在类别不平衡或边缘模糊区域的分割效果。此外,有效规避了单一依赖 Dice 损失可能引发的损失饱和问题,增强了模型训练的灵活性,使其能够更好地适应多样化的数据分布和任务需求,进而显著提升了模型的整体性能与鲁棒性。

对于 GGCA 机制,其分组数量 G 的取值决定了输入特征图在通道维度上的分组方式,进而影响特征提取的粒度和计算效率。分组数量的增加使得特征图在通道维度上被细分为更多的子组,每个子组独立进行特征提取和注意力计算。通过这种细粒度的分组方式能够捕捉到更局部的特征信息,从而增强模型对细节的感知能力。然而,当分组数量过多时,每个子组的通道数减少,这可能导致特征表示的丰富度不足,从而影

响模型的整体性能。由表 2 可知,分组数量为 2 时,特征图在通道维度上被适度分割,模型能够更有效地捕捉局部特征信息,同时保持通道间的协同作用。这种分组方式既增强了模型对细节的感知能力,又避免了分组过多导致的特征信息分散。相比之下,分组数量为 1 时,模型无法充分利用通道分组带来的优势;而分组数量为 4 时,每个分组的通道数减少,导致特征表示的丰富度不足,从而对模型的性能造成影响。

表 2 不同分组数量下的模型性能对比

Table 2 Comparison of model performance under different group numbers

G	mPA / %	mIoU / %
1	96.48	91.89
2	96.56	92.09
4	96.51	91.92

4.4 消融实验

为验证所提改进措施对模型性能提升的有效性,以原始 U-Net 模型为对比基准,在测试集上进行测试,对所提出的网络架构进行了消融实验分析,实验结果如表 3 和表 4 所示。其中,基准为 U-Net 模型。从表 3 可以看出,在引入一系列改进措施后,基准模型性能得到了显著提升。与基准模型相比,改进后模型的 mIoU、mPA、ACC 评价指标分别提升了 2.33 百分点、0.89 百分点和 0.15 百分点。

表 3 消融实验结果对比(分割精度)

Table 3 Comparison of ablation experiment results (segmentation accuracy)

Model	VGG16	VoVGSCSP	Pretrain	GGCA	mIoU / %	mPA / %	ACC / %
Baseline	×	×	×	×	89.76	95.67	99.46
1	✓	×	×	×	90.80	95.90	99.54
2	✓	✓	×	×	90.91	96.07	99.55
3	✓	✓	✓	×	91.78	96.45	99.59
4	✓	✓	✓	✓	92.09	96.56	99.61

表 4 消融实验结果对比(模型大小)

Table 4 Comparison of ablation experiment results (model size)

Model	VGG16	VoVGSCSP	GGCA	Params / 10^6	FLOPs / 10^9	FPS
Baseline	×	×	×	34.527	131.045	34.95
1	✓	×	×	24.891	112.918	39.21
2	✓	✓	×	16.306	68.693	36.89
3	✓	✓	✓	16.351	68.741	35.21

表 4 展示了各个功能模块在融合后对模型实时性的影响。具体而言,以基准 U-Net 模型为基础,引入 VGG16 作为编码器后,模型的参数量(Params)降低了约 27.9%,浮点运算数(FLOPs)降低了约 13.8%,FPS 提升至 39.21。这一改进主要得益于模型第 5 层通道数从原始 U-Net 的 1024 个减少至 512 个,从而在保持精度的同时实现了模型的轻量化。此外,VGG16 编码器凭

借其强大的特征学习能力,显著削弱了模型对参数的依赖。

进一步地,当使用 VoVGSCSP 模块作为解码器时,尽管模型精度小幅提升,但是实时性有所下降。然而,模型的参数量和计算量分别降低了 34.49% 和 39.17%,这使得模型更适合在硬件资源受限的工业环境中部署。

在瓶颈结构中引入 GGCA 机制后,模型的参数量和计算量仅略有增加,但特征提取能力得到进一步提升。最终,模型的 FPS 稳定在 35.21,满足焊接作业现场对实时性的要求。

4.5 对比实验与分析

为了全面评估所提改进模型在焊缝激光条纹分割任务中的性能,在相同实验条件下,对所提模型与 U-Net、Deeplabv3+^[20] 和 PSP-Net^[21] 进行了对比实验。实验

以 ACC、mPA 和 mIoU 为性能评价指标,以测试集为评价数据集,其中 ACC、mPA 和 mIoU 值越高,表明模型的分割性能越优。

从图 10 的分割结果可以看出,原始 U-Net 模型的

输出较为平滑,但存在一定程度的误检现象,即噪声像素被错误识别为激光条纹。这主要是由于 U-Net 的特征提取能力有限,不同阶段提取的特征之间关联性不足,导致模型难以准确区分激光条纹与背景噪声。




图 10 不同算法分割结果对比

Fig. 10 Comparison of segmentation results using different algorithms

Deeplabv3+ 在分割过程中出现了漏检现象,分割得到的激光条纹存在不连续性。这表明该模型对全局视野和上下文信息的关注度不足,难以完整捕捉连续的激光条纹。

PSP-Net 的分割结果中,激光条纹的边界较为粗糙。这是由于激光条纹本身较细,而该模型的感受野有限,无法充分覆盖激光条纹的复杂形状和细节信息。

相比之下,所提模型的分割结果最为平滑,且与标签图像高度相似。这表明该模型在特征提取、全局上下文信息感知以及细节捕捉方面具有显著优势,能够更准确地分割出激光条纹,同时有效抑制噪声和误检现象。

表 5 的定量实验结果表明,提出的改进型 U-Net 网络模型在分割精度方面具有显著优势,其 ACC、mPA 和 mIoU 均优于其他对比模型。这一性能提升主

表 5 所提算法与其他算法评价指标对比

Table 5 Comparison of evaluation indicators of the proposed algorithm and other algorithms

Algorithm	ACC / %	mPA / %	mIoU / %
U-Net	99.46	95.67	89.76
Deeplabv3+	99.51	95.86	90.19
PSP-Net	99.34	94.93	87.75
Proposed	99.61	96.56	92.09

要归因于以下几个关键改进。首先,引入 VGG16 作为特征提取器,模型的特征提取能力得到显著增强,从而能够更有效地捕捉激光条纹的细节特征。其次,迁移学习的引入在一定程度上缓解了数据样本不足的问题,提升了模型对有限数据的利用效率,并增强了其泛化能力。再次,GGCA 机制进一步突出了目标区域的

特征,使模型能够更精准地聚焦于激光条纹,从而提高了分割精度。最后,VoVGSCSP模块不仅优化了模型的特征提取能力,还在保持轻量化的基础上进一步提升了模型分割性能。

在复杂的焊接作业环境中,改进的 U-Net 模型展现出优异的抗干扰能力,避免了干扰因素导致的分割精度下降问题。实验结果表明,所提模型在高噪声和背景干扰的条件下依然能够实现高精度的激光条纹分割,验证了其在实际工业场景中的有效性和鲁棒性。

激光条纹的高精度分割对于焊缝特征点的识别具有重要意义。在完成激光条纹图像的去噪分割后,采用灰度重心法对分割后的激光条纹图像进行中心线提取,如图 11 所示。对比从标签图像中提取的条纹中心线与实际分割中心线在列方向上的像素误差,实验结果如图 12 所示。与 3 种对比模型相比,提出的模型所

提取的中心线与原始图像更为接近,最大误差仅为 1 pixel。这一结果表明,该模型在激光条纹分割精度上显著优于其他对比模型,展现出更优的激光条纹提取效果。




图 11 激光条纹中心线提取结果

Fig. 11 Extraction result of laser stripe centerline




图 12 激光条纹中心线提取误差结果。(a) U-Net; (b) Deeplabv3+; (c) PSP-Net; (d) 所提模型

Fig. 12 Error results of laser stripe centerline extraction. (a) U-Net; (b) Deeplabv3+; (c) PSP-Net; (d) proposed

5 结 论

针对焊接作业中弧光、飞溅等干扰因素导致的焊缝激光条纹分割问题,如漏检、误检以及分割精度低等现象,提出了一种基于改进 U-Net 神经网络的焊缝激光条纹分割模型。

1)通过引入 VGG16 编码器、VoVGSCSP 模块和 GGCA 机制等改进措施,有效提升了模型的特征提取能力、鲁棒性和分割精度。实验结果表明,所提模型相

较于对比模型具有更高的分割精度,能够更有效分割激光条纹。

2)通过采用混合损失函数,有效缓解激光条纹像素与背景像素比例失衡的问题;采用迁移学习的策略,提高模型的收敛能力,降低模型训练过程中对大规模数据集的依赖性。

3)改进模型相较于原始模型具有更低的参数量和计算复杂度,FPS 达到 35.21,能够在算力有限的工业生产场景中部署,并满足高精度、轻量化且低延迟的视

觉分割需求。

参 考 文 献

- [1] Du R Q, Xu Y L, Hou Z, et al. [Strong noise image processing for vision-based seam tracking in robotic gas metal arc welding](#)[J]. The International Journal of Advanced Manufacturing Technology, 2019, 101(5): 2135-2149.
- [2] 张弓, 脱帅华, 曹学鹏, 等. 焊接机器人焊缝跟踪技术的现状与发展趋势[J]. 科学技术与工程, 2021, 21(10): 3868-3876.
Zhang G, Tuo S H, Cao X P, et al. The state-of-the-art and developing trends of weld seam tracking technology of welding robot[J]. Science Technology and Engineering, 2021, 21(10): 3868-3876.
- [3] 商执亿, 王建华, 尹培丽, 等. [金属表面非相干线结构光条纹中心提取方法](#)[J]. 应用光学, 2022, 43(3): 503-509.
Shang Z Y, Wang J H, Yin P L, et al. [Extraction of incoherent linear structured light stripe center on metal surface](#)[J]. Journal of Applied Optics, 2022, 43(3): 503-509.
- [4] 李东洁, 宋贺, 徐立航. [一种基于激光视觉的焊缝实时检测技术研究](#)[J]. 激光与红外, 2019, 49(7): 818-823.
Li D J, Song H, Xu L H. [A real-time welding seam detection technology based on laser vision](#)[J]. Laser & Infrared, 2019, 49(7): 818-823.
- [5] 孙王倩, 祁卓, 李少晨, 等. [基于MSER的线激光光条中心提取算法](#)[J]. 应用激光, 2022, 42(2): 71-77.
Sun W Q, Qi Z, Li S C, et al. Method for extracting the centerline of line structured laser light based on MSER[J]. Applied Laser, 2022, 42(2): 71-77.
- [6] 成佳明, 靳慧, 郑子健, 等. [基于机器视觉的施工现场钢结构焊缝坡口识别](#)[J]. 东南大学学报(自然科学版), 2023, 53(1): 86-93.
Cheng J M, Jin H, Zheng Z J, et al. Welding seam groove recognition of steel structure on construction site based on machine vision[J]. Journal of Southeast University (Natural Science Edition), 2023, 53(1): 86-93.
- [7] Wang N F, Yang J L, Zhang X M, et al. [Robust weld seam tracking method based on detection and tracking of laser stripe](#)[J]. The International Journal of Advanced Manufacturing Technology, 2024, 130(7): 3481-3493.
- [8] 张世宽, 吴清潇, 林智远. [焊缝图像中结构光条纹的检测与分割](#)[J]. 光学学报, 2021, 41(5): 88-96.
Zhang S K, Wu Q X, Lin Z Y. [Detection and segmentation of structured light stripe in weld image](#)[J]. Acta Optica Sinica, 2021, 41(5): 88-96.
- [9] Yu W B, Li Y, Yang H T, et al. [The centerline extraction algorithm of weld line structured light stripe based on pyramid scene parsing network](#)[J]. IEEE Access, 2021, 9: 105144-105152.
- [10] Rashid S N, Fraz M M, Javed S. [Multiscale dilated UNet for segmentation of multi-organ nuclei in digital histology images](#)[C]//2020 IEEE 17th International Conference on Smart Communities: Improving Quality of Life Using ICT, IoT and AI (HONET), December 14-16, 2020, Charlotte, NC, USA. New York: IEEE Press, 2020: 68-72.
- [11] Ronneberger O, Fischer P, Brox T. [U-net: convolutional networks for biomedical image segmentation](#)[M]//Navab N, Hornegger J, Wells W M, et al. Medical image computing and computer-assisted intervention- MICCAI 2015. Lecture notes in computer science. Cham: Springer International Publishing, 2015, 9351: 234-241.
- [12] Simonyan K, Zisserman A. [Very deep convolutional networks for large-scale image recognition](#)[EB/OL]. (2014-09-04)[2024-12-12]. <https://arxiv.org/abs/1409.1556v6>.
- [13] Tavera A, Cermelli F, Masone C, et al. [Pixel-by-pixel cross-domain alignment for few-shot semantic segmentation](#)[C]//2022 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), January 3-8, 2022, Waikoloa, HI, USA. New York: IEEE Press, 2022: 1959-1968.
- [14] 王军敏, 樊养余, 李祖贺. [基于深度卷积神经网络和迁移学习的纹理图像识别](#)[J]. 计算机辅助设计与图形学学报, 2022, 34(5): 701-710.
Wang J M, Fan Y Y, Li Z H. [Texture image recognition based on deep convolutional neural network and transfer learning](#)[J]. Journal of Computer-Aided Design & Computer Graphics, 2022, 34(5): 701-710.
- [15] Niu Z Y, Zhong G Q, Yu H. [A review on the attention mechanism of deep learning](#)[J]. Neurocomputing, 2021, 452: 48-62.
- [16] Li H L, Li J, Wei H B, et al. [Slim-neck by GSConv: a lightweight-design for real-time detector architectures](#)[J]. Journal of Real-Time Image Processing, 2024, 21(3): 62.
- [17] Chollet F. [Xception: deep learning with depthwise separable convolutions](#)[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 21-26, 2017, Honolulu, HI, USA. New York: IEEE Press, 2017: 1800-1807.
- [18] Liu Q, Liu H T, Zhao Y, et al. [Dual-branch network with dual-sampling modulated dice loss for hard exudate segmentation in color fundus images](#)[J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(3): 1091-1102.
- [19] Qian X L, Gao S G, Deng W, et al. [Improving oriented object detection by scene classification and task-aligned focal loss](#)[J]. Mathematics, 2024, 12(9): 1343.
- [20] da Cruz L B, Júnior D A D, Diniz J O B, et al. [Kidney tumor segmentation from computed tomography images using DeepLabv3+ 2.5D model](#)[J]. Expert Systems with Applications, 2022, 192: 116270.
- [21] Zhao H S, Shi J P, Qi X J, et al. [Pyramid scene parsing network](#)[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), July 21-26, 2017, Honolulu, HI, USA. New York: IEEE Press, 2017: 6230-6239.